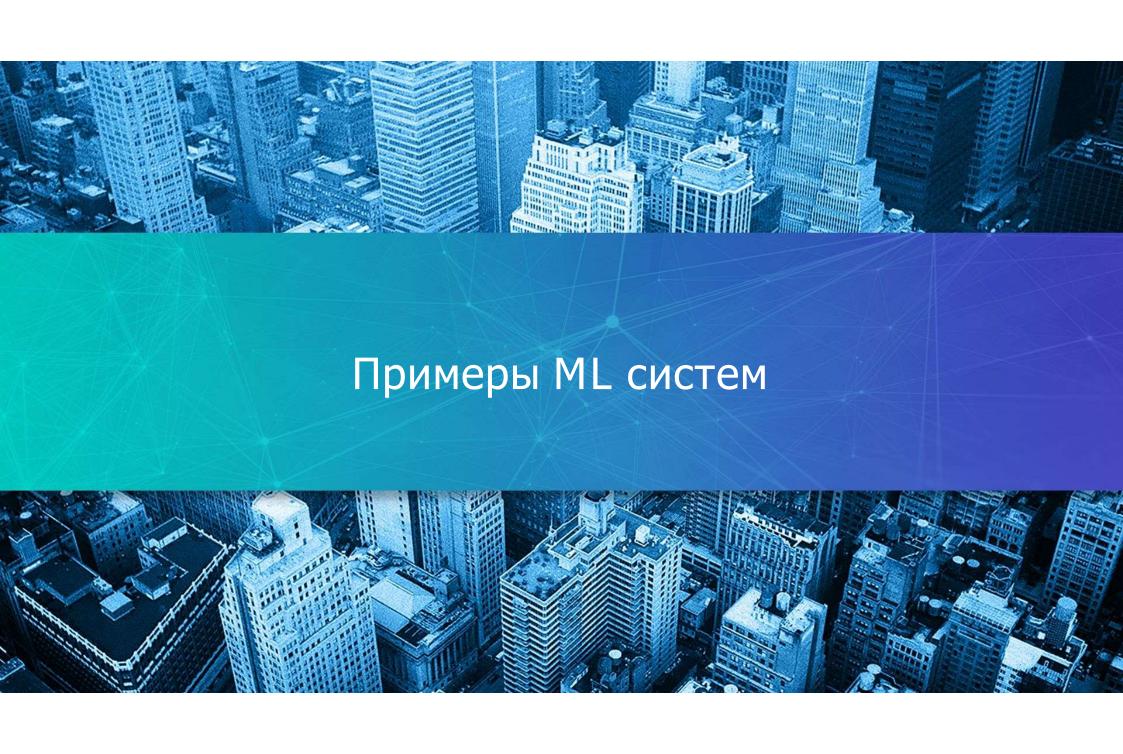


Вопросы

1.Пакетная обработка

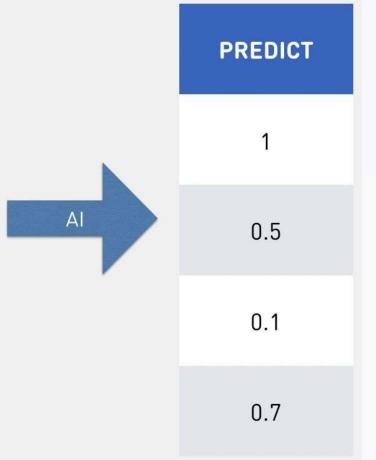
2. Асинхронный режим

3.Синхронный режим

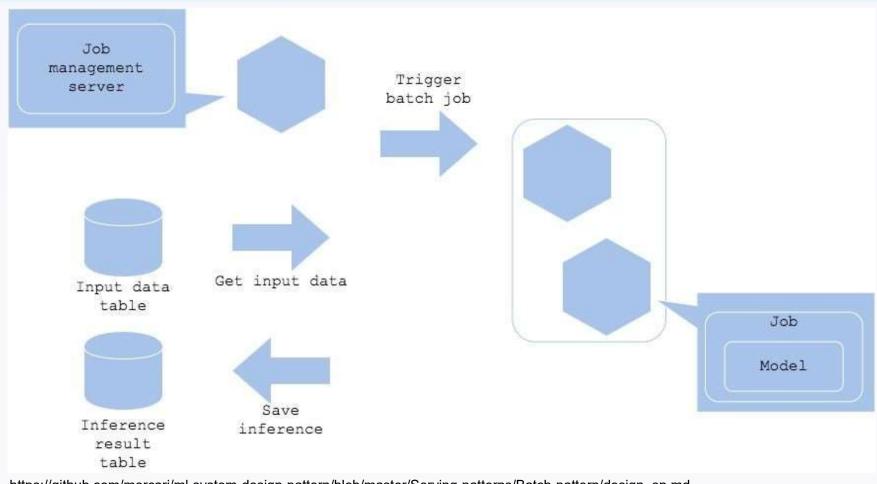


Классический банковский ML

Index	пол	возраст	зп
0	М	23	300 к/сек
1	М	33	45 000 р/мес
2	М	34	15 000 р/мес
3	Ж	55	55 000 р/мес



Пакетная обработка (пакетный паттерн)



 $https://github.com/mercari/ml-system-design-pattern/blob/master/Serving-patterns/Batch-pattern/design_en.md\\$

Пакетный паттерн - когда нужно использовать?

- Если не нужно получать результат в реальном или почти реальном времени
- Для массивной обработки данных
- Когда для корректной работы достаточно запускать процесс PREDICTION по расписанию
- Подходит для большей части ETL

Как это обычно выглядит?

- 1) Считаются фичи по данным за предыдущий день(много джоб)
- 2) Берем модель(обучаем модель) и делаем предсказание
- 3) Смотрим на предсказания, если их распределение норм, то заливаем в **прод**, если нет, то посылаем предупреждение, о том, что-то пошло не так.
- 4) Делать надо каждый день

Cron

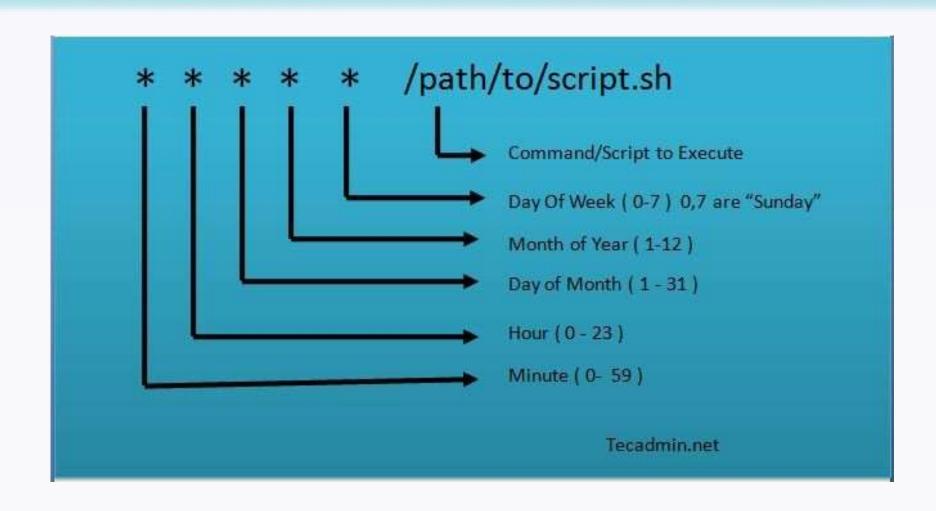
Cron - unix утилита, используемая для периодического выполнения заданий в определенное время.

Регулярные действия описываются инструкциями в **crontab** и специальных каталогах

Crontab

```
worker1: ~ cronitor list
  Reading user "ubuntu" crontab
  SCHEDULE
                        COMMAND
                       /var/app/edi/send_batch_invoices.py
/var/app/edi/send_batch_settlement.py
                       /var/app/edi/reconciler.sh --full
                        /var/app/reporting/rollup minute
                        /var/app/reporting/rollup hour
                       /var/app/reporting/rollup day
                       /var/app/reporting/rollup archive-ancient-data
  Reading /etc/crontab
                       COMMAND
  SCHEDULE
                       /tmp/foo.sh --systemcrontab
  0 * * * *
worker1: ~
```

Crontab

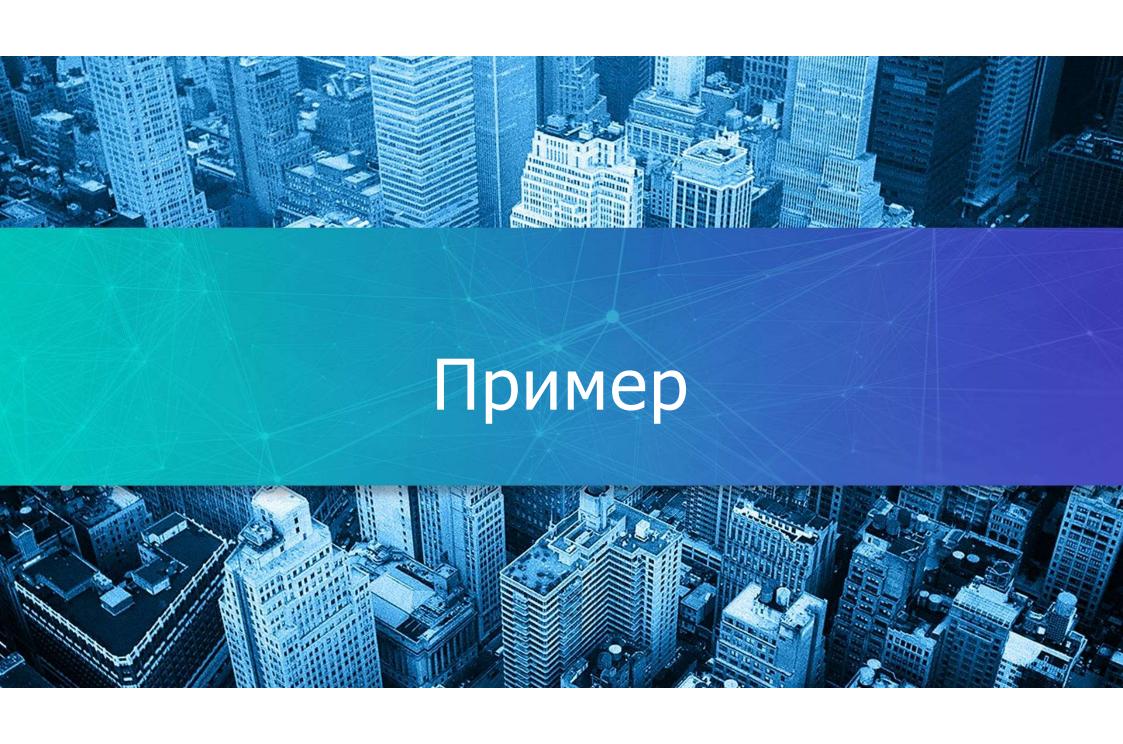


Как cron можно применить?

Помним, что нам нужно запустить несколько задач подряд

- 1) определяем время старта и конца каждой таски и запускаем несколько cron-job
- 2) запихиваем все таски в один cronjob

```
spark-submit job1 spark-submit job2 etc
```



Минусы cron

- трудно мониторить
- нет автоматических перезапусков
- нельзя явно задавать связи между задачами

```
#30 2 * * * spark-submit --master yarn --queue root.daily --executor-cores=8 --executor-memory=16G --class BanReport /mnt/h
#30 4 * * * spark-submit --master yarn --queue root.daily --executor-cores=4 --executor-memory=32G --class BanGenerator /mn

30 5 * * * spark2-submit --master yarn --queue root.daily --executor-cores=4 --executor-memory=8G --class etl.RequestOtahot

#30 6 * * * spark-submit --master yarn --queue root.daily --executor-cores=8 --executor-memory=16G --class etl.DAPIToParquet /mnt/hadoop/spark-

#31 * * * * spark-submit --master yarn --executor-cores=4 --executor-memory=8G --class DiscrepancyHunter /mnt/hadoop/spark-

#33 * * * * spark-submit --master yarn --executor-cores=8 --executor-memory=16G --class DiscrepancyInStep /mnt/hadoop/spark-

#33 * * * * spark-submit --master yarn --executor-cores=8 --executor-memory=16G --class DiscrepancyInStep /mnt/hadoop/spark-

#40 * * * spark-submit --master yarn --queue root.hourly --executor-cores=4 --executor-memory=8G --class etl.Discrepancy

#40 * * * spark-submit --master yarn --queue root.hourly --executor-cores=4 --executor-memory=8G --class etl.DiscrepancyHu

#40 * * * spark-submit --master yarn --queue root.hourly --executor-cores=4 --executor-memory=8G --class etl.RaIndex /mnt
```

Что нам хотелось бы?

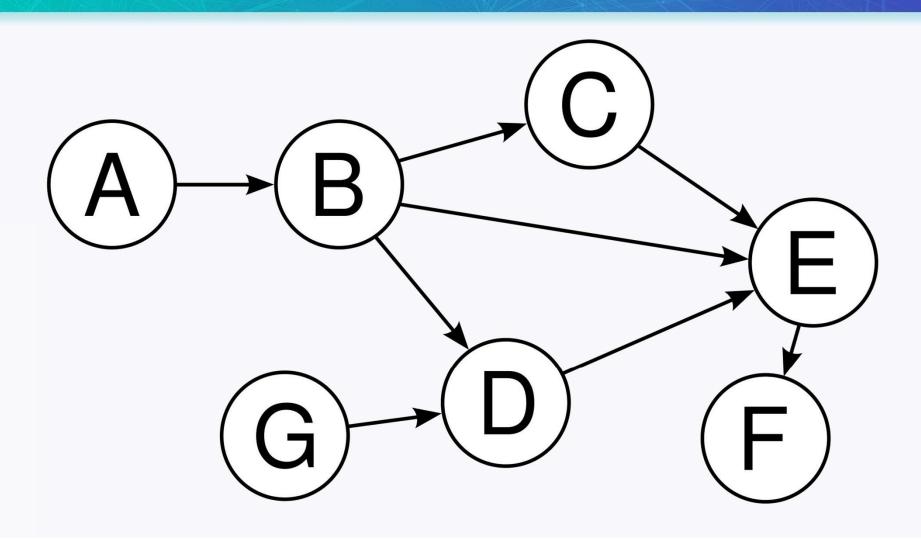
- возможность запускаться по расписанию
- запускать задачи друг за другом в зависимости от чего-либо
- мониторинг, если что-то упало и перезапуск
- декларативное описание графа выполнения

Оркестраторы

Оркестратор -- это штука, которая отвечает за:

- **Планирование задач** (когда запустить)
- **Управление зависимостями** (ждать пока исполнятся другие задачи перед запуском)
- **Репроцессинг** легко перезапускать упавшие задачи и зависящие от неё
- Мониторинг если задача упала, то нужно об этом уведомить

DAG - Directed Acyclic Graph



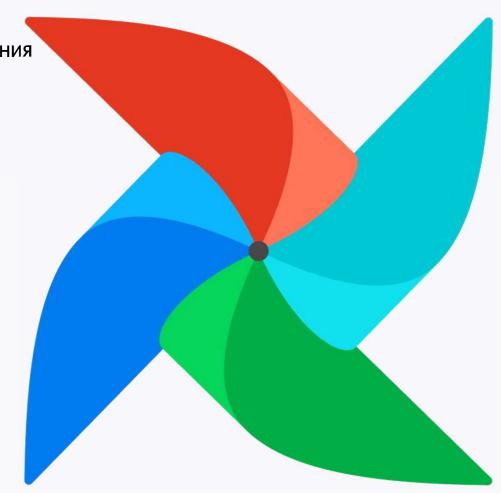


Что такое Apache Airflow

Apache Airflow - платформа для автоматического управления задачами, их расписанием и мониторингом

Разрабатывается с 2014 года(изначально в Airbnb https://github.com/apache/airflow





Как задаются DAG в Airflow?

- Даги в airflow задаются питоновским **кодом**
- Поддерживаются сложные штуки, вроде ветвлений и описания зависимостей из нескольких задач
- Легко расширяется кастомными задачами

```
dag = DAG(
    "easy pipeline",
    default_args=default_args,
    description="An easy airflow DAG",
    schedule_interval=timedelta(days=1),
task_1 = BashOperator(
    task id="print date",
    bash_command="date",
    dag=dag)
task_2 = BashOperator(
    task_id="sleep",
    depends_on_past=False,
    bash_command="sleep 5",
    retries=3.
    dag=dag
task_1 >> task_2
```

Интерфейс Airflow - даги



DAGs

Tools *

Browse ▼

Admin -

Docs*

DAGs

DAG	Filepath	Owner	Task by State	Links
example1	example_dags/example1.py	airflow	80 1 0	◆*山水三ヶ≣
example2	example_dags/example2.py	airflow	128 10 0	◆ # 山 水 亖 ヶ ☰
example3	example_dags/example3.py	airflow	138 5 0	◆*山水三ヶ三

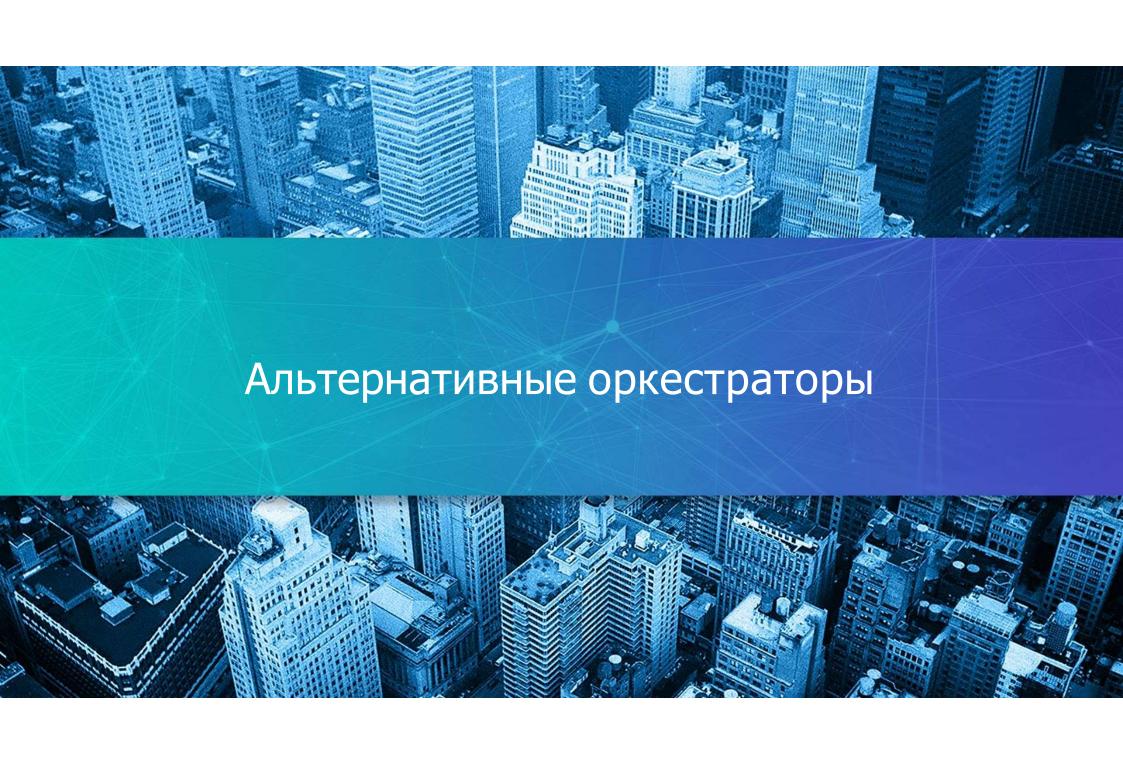
Интерфейс Airflow - таски



Как даги можно запускать?

- по расписанию (весь крон к нашим услугам)
- **через UI** (обычно используется, когда что-то упало)
- **Через API** (когда интегрируете airflow с внешними системами) http://airflow.apache.org/docs/stable/rest-api-ref.html

Cron Presets meaning preset cron Don't schedule, use for exclusively "externally triggered" DAGs None Schedule once and only once @once @hourly Run once an hour at the beginning of the hour 0 * * * 00 * * * Run once a day at midnight @daily Run once a week at midnight on Sunday morning 00 * * 0 @weekly Run once a month at midnight of the first day of the month 0 0 1 * * @monthly Run once a quarter at midnight on the first day 0 0 1 */3 * @quarterly @yearly Run once a year at midnight of January 1 0 0 1 1 *

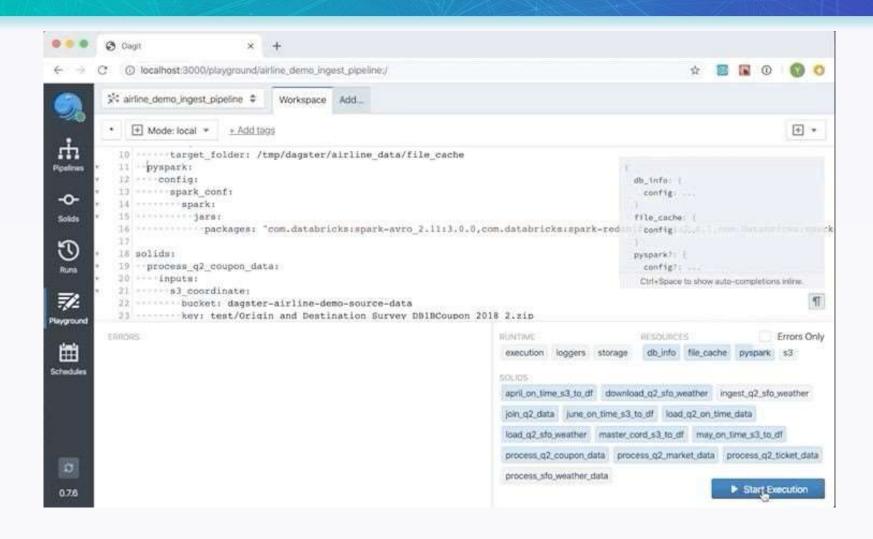


Luig

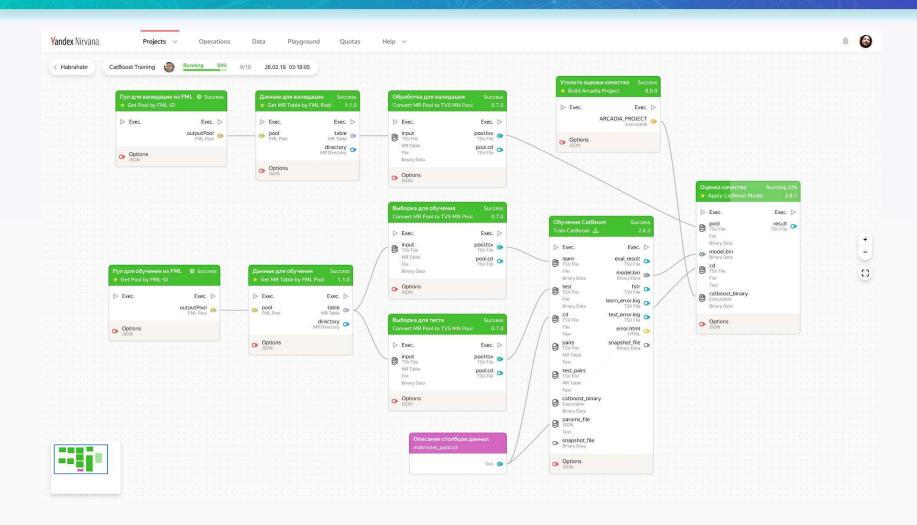
Довольно старый оркестратор, очень похожий на airflow **не содержит функционал шедулинга**

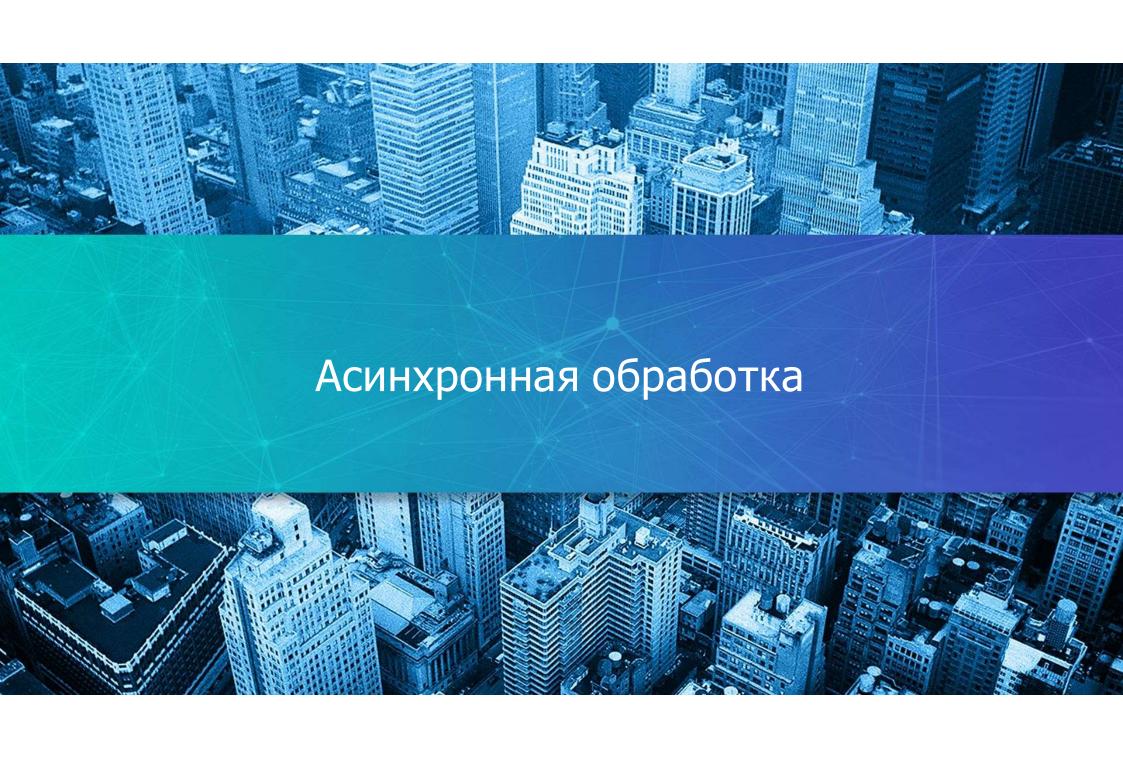
```
class MyTask1(luigi.Task):
   x = luigi.IntParameter()
    y = luigi.IntParameter(default=0)
    def run(self):
        print(self.x + self.y)
class MyTask2(luigi.Task):
   x = luigi.IntParameter()
    y = luigi.IntParameter(default=1)
    z = luigi.IntParameter(default=2)
    def run(self):
        print(self.x * self.y * self.z)
if __name__ == '__main__':
   luigi.build([MyTask1(x=10), MyTask2(x=15, z=3)])
```

Dagster

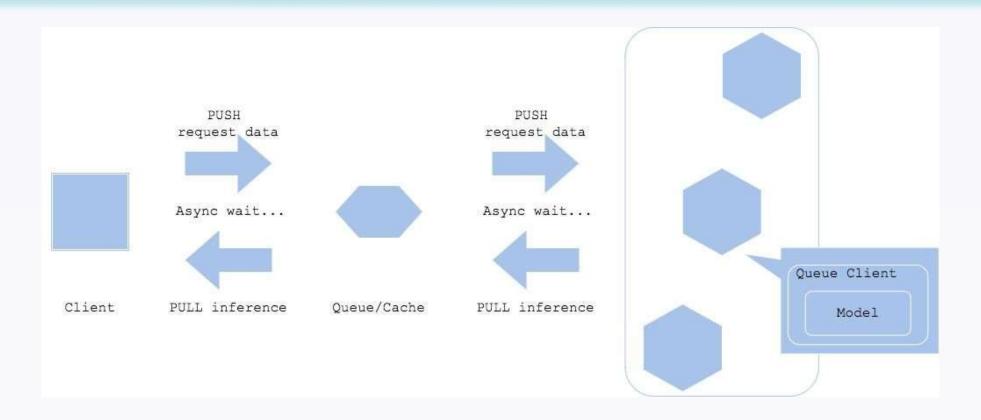


Яндекс Нирвана



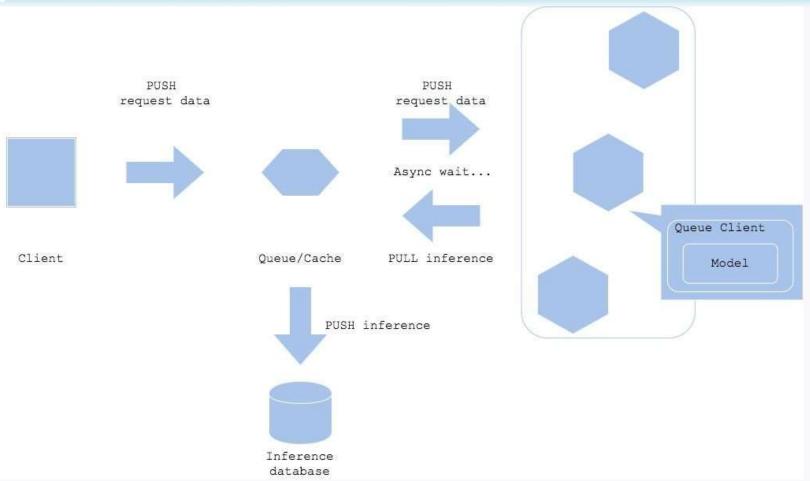


Асинхронный паттерн



https://github.com/mercari/ml-system-design-pattern/blob/master/Serving-patterns/Asynchronous-pattern/design_en.md

Асинхронный паттерн



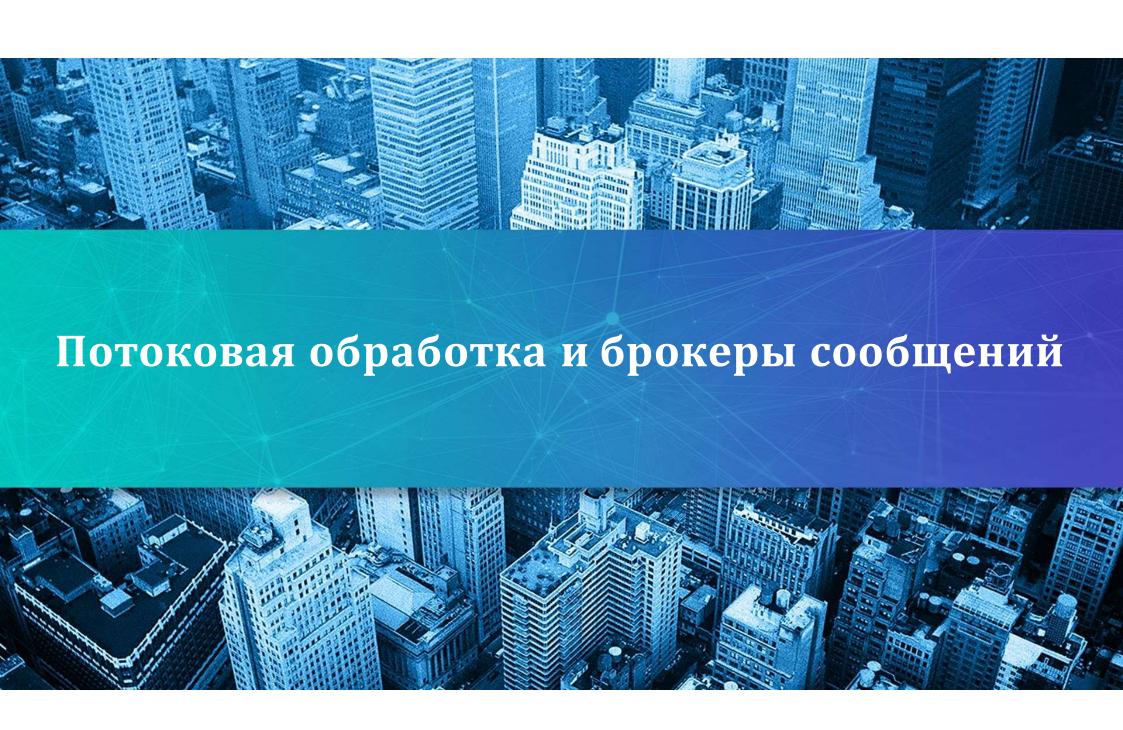
https://github.com/mercari/ml-system-design-pattern/blob/master/Serving-patterns/Asynchronous-pattern/design_en.md

Асинхронный паттерн - когда нужно использовать?

Если не нужно обрабатывать прямо сейчас

плюсы	минусы	
Можно отделить бизнес логику и логику предсказания	Как правило не подходит для обработки в реальном времени	
Более высокая(синхронным) пропускная способность	Нужны очереди/кеши, etc	
Вы не заблокированы временем предсказания		

https://github.com/mercari/ml-system-design-pattern/blob/master/Serving-patterns/Asynchronous-pattern/design_en.md

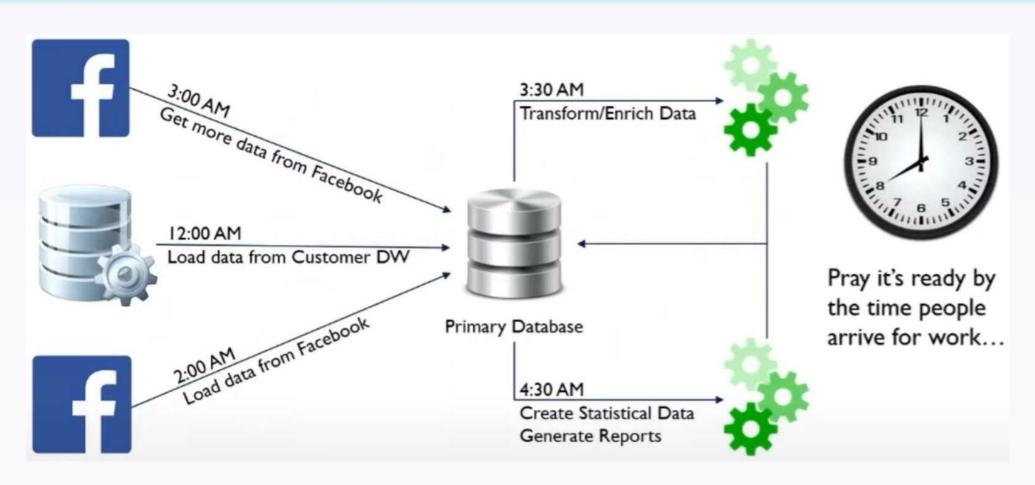


Quick recap

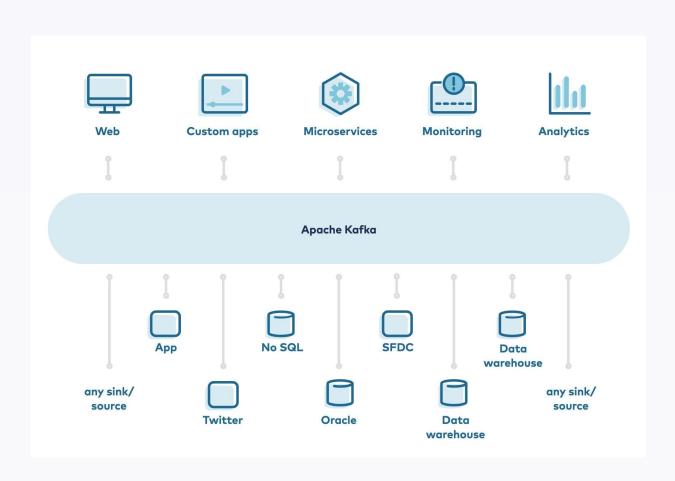
1) Данные собираем в очередь. Наиболее распространенный брокер - Kafka.

- 2) Из очереди обрабатываем потоково, либо батчами.
- 3) Потоковых фреймворков много, нет серебряной пули.
- 4) Результаты пишем либо в очередь, либо складываем в хранилища.

Standard ETL



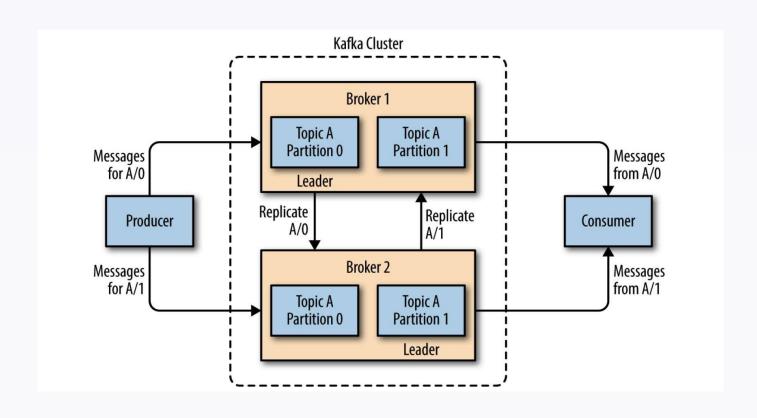
Quick recap. Kafka



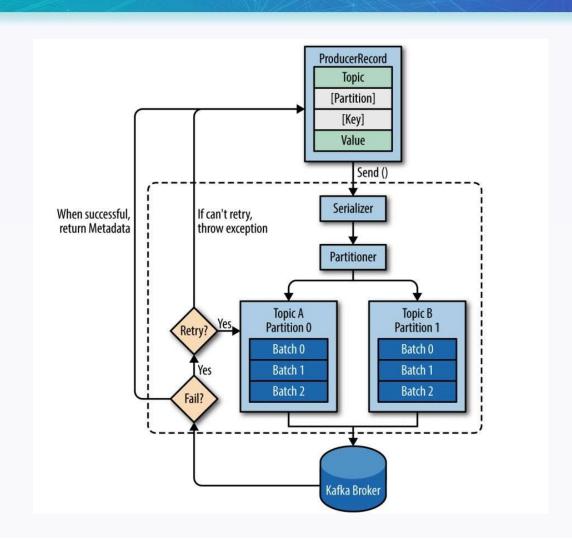
Ключевые возможности:

- 1. publish + subscribe
- 2. хранение
- 3. обработка

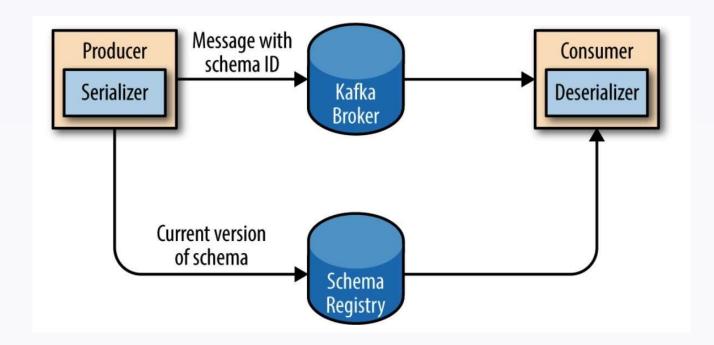
Quick recap. Kafka



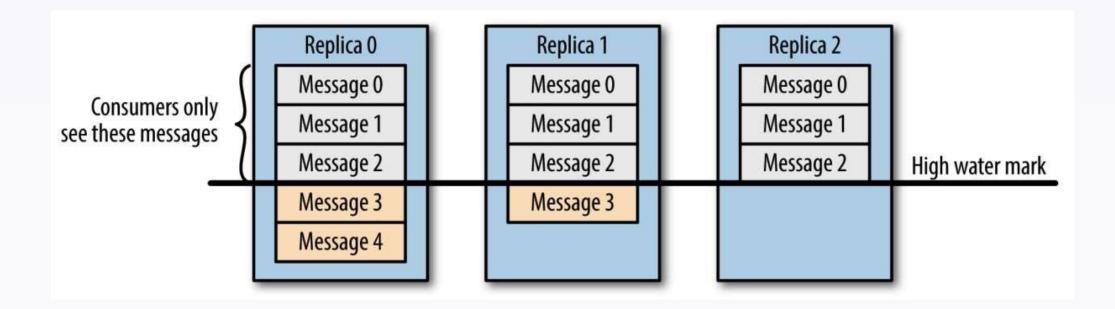
Quick recap. Kafka



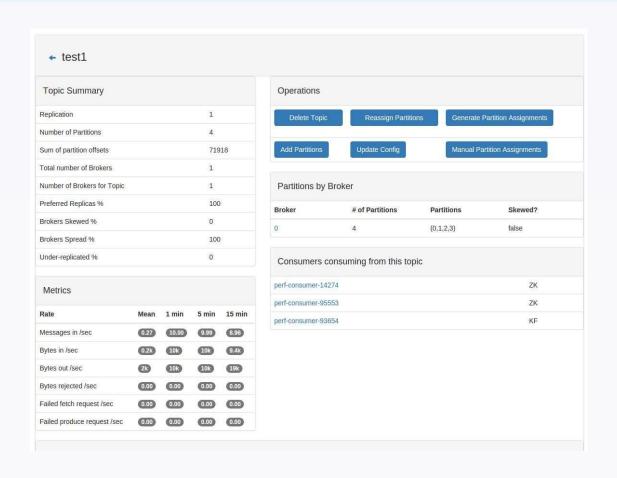
Quick recap. Kafka



Quick recap. Kafka



Cluster Manager for Apache Kafka

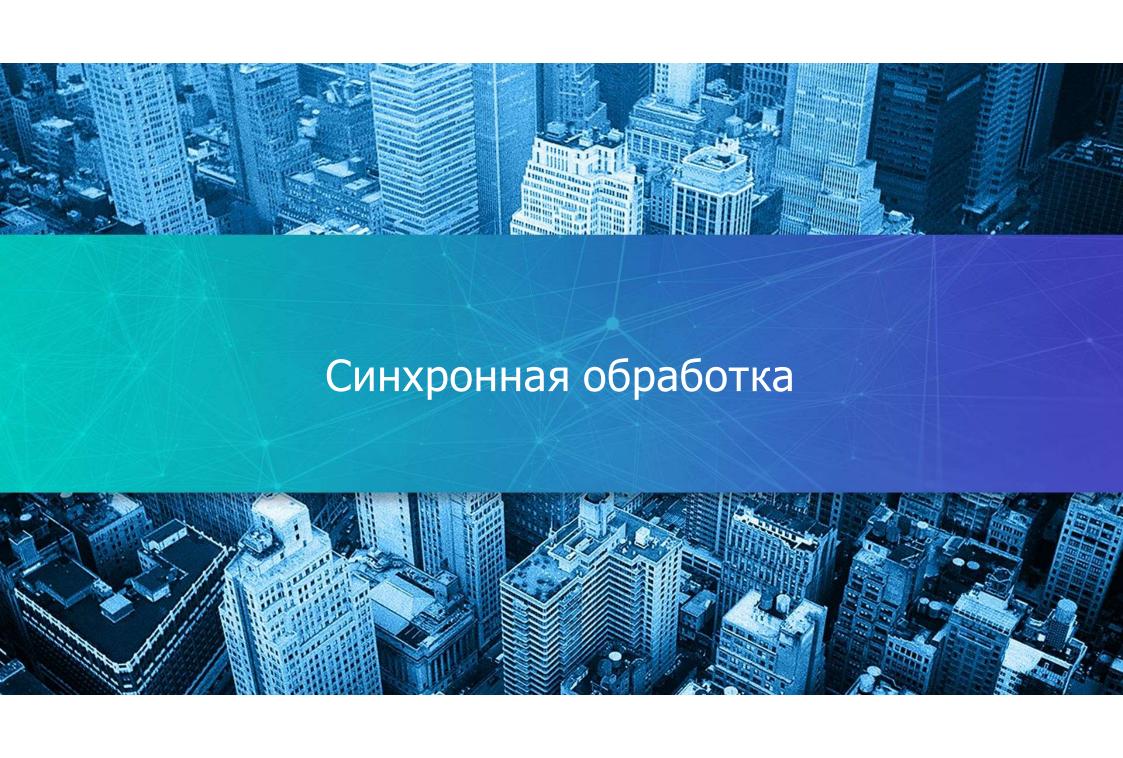


- Manage multiple clusters
- Easy inspection of cluster state (topics, consumers, offsets, brokers, replica distribution, partition distribution)
- Run preferred replica election
- Generate partition assignments with option to select brokers to use
- Run reassignment of partition
- Create a topic with optional topic configs
- Delete topic
- Topic list now indicates topics marked for deletion
- Batch generate partition assignments for multiple topics with option to select brokers to use
- Batch run reassignment of partition for multiple topics
- Add partitions to existing topic
- Update config for existing topic

Python libs for Apache Kafka

no. msg	1K	10K	100K	1M
confluent-producer-async	0.02s	0.06s	0.53s	4.34s
confluent-producer-sync	3.15s	31.12s	309.29s	x
confluent-consumer	3.07s	3.08s	3.32s	5.66s
pykafka-producer-async	10.04s	15.38s	12.41s	45.69s
pykafka-producer-sync	6.93s	24.33s	188.89	x
pykafka-consumer	0.26s	0.84s	6.91s	60.69s
kafka-python-producer-async	0.08s	0.67s	6.72s	68.26s
kafka-python-producer-sync	3.27s	30.81s	318.29	x
kafka-python-consumer	0.06s	0.78s	3.15s	33.94s

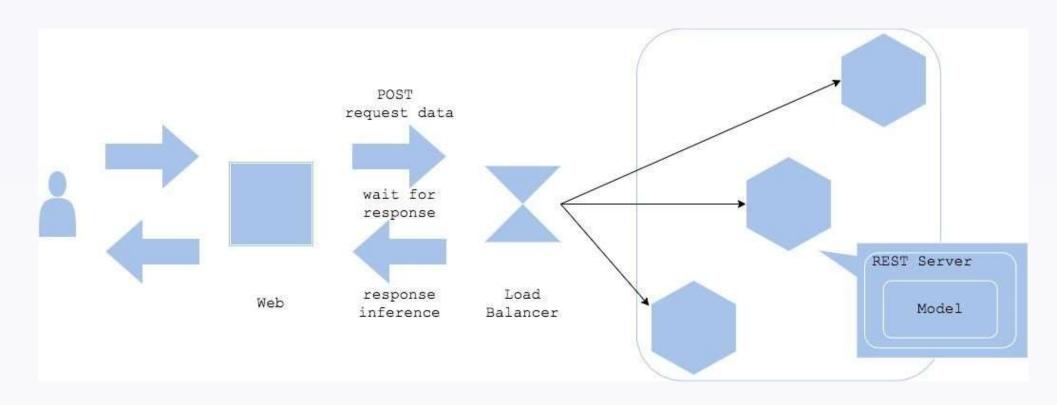
https://towardsdatascience.com/3-libraries-you-should-know-to-master-apache-kafka-in-python-c95fdf8700f2



Нейронная сеть - выделяет объекты на изображении



Синхронный паттерн



https://github.com/mercari/ml-system-design-pattern/blob/master/Serving-patterns/Synchronous-pattern/design_en.md

Синхронный паттерн - когда нужно использовать?

Когда нужен результат предсказания, чтобы сделать следующий шаг

плюсы	минусы	
Очень просто реализовать	Скорость предсказания будет бутылочным горлышком производительности системы	
Как правило, низкое latency	Если предсказание долгое, то нужно, чтобы пользователь этого не замечал	

https://github.com/mercari/ml-system-design-pattern/blob/master/Serving-patterns/Synchronous-pattern/design_en.md



Representational State Transfer

Центральная идея: концепция распределенного приложения, в которой каждый запрос клиента (REST-запрос) содержит в себе исчерпывающую информацию о желаемом ответе сервера, и сервер не обязан сохранять информацию о состоянии клиента (клиентскую сессию).

Сам термин REST впервые упоминается в диссертации Роя Филдинга, одного из создателей протокола HTTP.

Пример RESTless: FTP

220 Hello World!

USER anonymous

331 Anonymous login ok, send your complete email address as your password

PASS ********

230 Logged in anonymously.

PASV

227 Entering Passive Mode (192,168,254,253,233,92) //Клиент должен открыть соединение на переданный IP

LIST

150 Here comes the directory listing.

226 Directory send OK.

QUIT

221 Goodbye.

Пример RESTfull: HTTP

GET / HTTP/1.1

Host: example.com

Authorization: Bearer <token>

HTTP/1.1 200 OK

Date: Sat, 09 Oct 2010 14:28:02 GMT

Server: Apache

Last-Modified: Tue, 01 Dec 2009 20:18:22 GMT

Content-Length: 29769

Content-Type: text/html

<!DOCTYPE html> (остальные байты запрошенного ресурса)

Практическое использование REST

Самые частые реализации REST архитектуры используют:

- протокол HTTP/1.1
- шифрование TLS
- формат сериализации JSON
- аутентификация JWT

REST API на python











FastAPI



Sebastián Ramírez @tiangolo · 11 июл. 2020 г.

I saw a job post the other day.

It required 4+ years of experience in FastAPI. 🙎

I couldn't apply as I only have 1.5+ years of experience since I created that thing.

Maybe it's time to re-evaluate that "years of experience = skill level".



176,7 тыс.



FastAPI

- высокая производительность (благодаря Starlette и pydantic)
- быстрая скорость разработки
- позволяет делать меньше багов
- интуитивный интерфейс
- легкий в изучении
- небольшой объем кода
- production ready с автоматическим документированием
- основан на стандартах OpenAPI (Swagger) и JSON Schema

Пример: FastAPI

```
demo.py:
     from fastapi import FastAPI
     app = FastAPI()
     @app. get ("/")
     def read_healthcheck():
          return {"status": "Green"}
Запуск:
     $uvicorn main.app --reload
```

Итоги - тезисы

- Рассмотрели каждый паттерн
- Рассмотрели пример на spark
- Узнали про альтернативные оркестраторы
- Рассмотрели синхронный и асинхронный паттерны

